



TECNOLOGIA SUPERIOR

BIG DATA E INTELIGENCIA DE NEGOCIO

MACHINE LEARNING

WILLIAM ESTUARDO JIMÉNEZ MIGUEZ

william.jimenez@cenestur.edu.ec

Profesor: JOHANNA CRISTINA JARA BUSTILLOS

johanna.jara@cenestur.edu.ec

Quito, Ecuador

2025

Resumen Ejecutivo

Pronóstico de demanda e inventario (M5, retail multi-tienda)

Problema de negocio. La cadena de suministro enfrenta dos dolores simultáneos: quiebres de stock (pérdida de ventas y satisfacción) y sobreinventario (capital inmovilizado y mermas). La planificación manual y reglas estáticas no capturan estacionalidad, promociones ni shocks de demanda.

Solución propuesta. Implementar un pronóstico de ventas por SKU-tienda y convertirlo en políticas de reabastecimiento (stock objetivo, punto de pedido, stock de seguridad). El núcleo es un modelo supervisado global que aprende patrones comunes entre miles de series y usa variables de calendario, precio, lags y promedios móviles. Para afinar la política de inventario, se complementa con simulación para equilibrar servicio vs. costo.

Evidencia y caso de referencia. Se toma como base el dataset público M5 Forecasting (Walmart), estándar del sector para evaluación de pronósticos jerárquicos por producto-tienda. Esto permite reproducibilidad, benchmarking y una validación rigurosa. Se entregó un notebook listo para ejecutar con pipeline completo.

Datos y metodología.

- **Datos:** ventas históricas (SKU-tienda), calendario (feriados/SNAP), precios semanales y metadatos (categoría, departamento).
- **Modelado:** comparación de *baselines* (Naive, estacional) vs. LightGBM; validación con ventana rodante y horizonte de 28 días.
- **Métricas de pronóstico:** MAE, RMSE y WMAPE (para demanda dispareja).
- **Inventario:** cálculo de stock de seguridad con intervalos de pronóstico (p50/p90) y evaluación en simulación con fill-rate, OTIF, costo total.
- **Operacionalización:** tablero de KPIs y alarmas de *drift* para monitoreo continuo (MLOps).

Qué se espera lograr.

- Menos quiebres y mejor nivel de servicio (fill-rate).
- Reducción de inventario no productivo (mejor rotación y días de inventario).
- Planificación más estable ante promociones y estacionalidad, con explicabilidad vía importancias de variables.

Indicadores clave de éxito (a reportar).

- **Pronóstico:** WMAPE/MAE/RMSE por tienda, categoría y total.
- **Inventario/servicio:** fill-rate, OTIF, costo total (posesión + quiebre + pedido), rotación, tasa de quiebres.
- **Operación:** cumplimiento del plan, *drift* de datos/modelo y tiempos de cómputo.

Riesgos y mitigación.

- Calidad/integridad de datos: rutinas de validación y *backfilling* de precios.
- Cambios de patrón (concept drift): re-entrenos programados y *champion/challenger*.
- Demanda intermitente: uso de WMAPE y modelos con lags/rolling + intervalos (pinball loss/quantiles).

Con datos disponibles y una validación robusta basada en M5, el pronóstico por SKU-tienda y su traducción a políticas de reabastecimiento constituyen una vía directa para mejorar servicio al cliente y liberar capital de trabajo. El piloto propuesto permite cuantificar beneficios en pocas semanas y escalar con bajo riesgo.

Introducción.

Las cadenas de suministro minoristas enfrentan dos problemas recurrentes: quiebres de stock que deterioran el servicio al cliente y sobreinventario que inmoviliza capital y genera mermas. Estos fenómenos se intensifican por la estacionalidad, las promociones, la variación de precios y cambios abruptos en la demanda, factores que los enfoques manuales o reglas estáticas no capturan con suficiente precisión. Frente a ello, el aprendizaje automático ofrece una vía práctica para anticipar ventas y planificar el reabastecimiento con mayor exactitud y rapidez.

Este trabajo propone un sistema de pronóstico de demanda a nivel SKU-tienda basado en modelos supervisados (en particular, LightGBM) que integran señales de calendario, precio y comportamiento histórico (lags y promedios móviles). La solución traduce el pronóstico en políticas de inventario (stock objetivo, punto de pedido y stock de seguridad) evaluadas mediante simulación con métricas de negocio como fill-rate, OTIF y costo total. Como evidencia y base reproducible se emplea el dataset público M5 Forecasting (Walmart), estándar del sector para validar pronósticos jerárquicos.

Objetivo.

Diseñar, entrenar y validar un sistema de pronóstico de demanda por SKU-tienda basado en aprendizaje automático (LightGBM) usando el dataset M5, y traducir dicho pronóstico en políticas de inventario (stock de seguridad, punto de pedido y reabastecimiento) para mejorar el nivel de servicio y optimizar el capital de trabajo, medido por disminución del error de pronóstico.

Desarrollo.

Fase 1: Exploración y Selección del Caso de Uso

Actividad 1.1: Realizar una búsqueda exploratoria amplia de cómo el Machine Learning se está aplicando en diferentes industrias (salud, finanzas, manufactura, comercio electrónico, etc.). Utilicen bases de datos académicas, informes de consultoras tecnológicas y artículos de prensa especializada.

El uso del machine learning (ML) en diferentes sectores está transformando los métodos convencionales, mejorando la productividad y fomentando la creatividad. En el ámbito de la manufactura, los algoritmos de ML están optimizando el mantenimiento predictivo, agilizando las cadenas de suministro y mejorando el control de calidad mediante técnicas avanzadas de análisis de datos.

La industria de la salud utiliza ML para la medicina de precisión, diagnósticos predictivos y monitoreo de pacientes, lo que conduce a mejores resultados en la atención médica.

En los servicios financieros, el ML es ventajoso para la detección de fraudes, la automatización del comercio y la mejora de las interacciones bancarias personalizadas.

Los sectores de comercio minorista y comercio electrónico están incorporando ML para la gestión de inventarios, la predicción de la demanda y la personalización de las estrategias de marketing, lo que se traduce en una mayor satisfacción del cliente y en una operación más eficiente.

En el sector energético, el ML desempeña un papel crucial al mejorar la eficiencia energética, prever fallos en los equipos e incorporar fuentes de energía sostenible.

El transporte y la logística utilizan ML para optimizar rutas, prever la demanda y desarrollar tecnología de vehículos autónomos, lo que permite reducir gastos operativos y mejorar la seguridad.

El ML también beneficia a la agricultura al habilitar la agricultura de precisión, monitorear la salud de los cultivos y predecir rendimientos, lo que impulsa prácticas agrícolas sostenibles.

En la industria de la construcción, el ML ayuda en la gestión de proyectos, la evaluación de riesgos y la implementación de métodos de construcción avanzados para aumentar la eficiencia y la seguridad de los proyectos.

Actividad 1.2: Seleccionar un caso de uso específico. Deberán justificar brevemente por qué lo eligieron, mencionando su potencial impacto o la novedad de su aplicación.

Caso elegido: Pronóstico de demanda por SKU-tienda y planeación de inventario. Por qué:

- Impacto directo en nivel de servicio y capital de trabajo.
- Abundancia de datos históricos (ventas, promociones, calendario) viabiliza modelos supervisados.
- Evidencia pública de desempeño con datos reales: competencia M5 (Walmart) y despliegues en nube para planificación de demanda.

La inteligencia artificial está transformando la logística al optimizar cada etapa de la cadena de suministro. En los almacenes, analiza la demanda y los niveles de inventario para reorganizar estratégicamente el espacio, reduciendo tiempos de preparación de pedidos y aumentando la capacidad de almacenamiento. También facilita el seguimiento de envíos en tiempo real, anticipando retrasos y optimizando rutas según el tráfico para garantizar entregas más rápidas y confiables. En la gestión de inventarios, automatiza la reposición y minimiza errores, mientras que en la asignación de recursos distribuye

las tareas de acuerdo con la carga de trabajo y las habilidades del personal, ajustándose incluso a las variaciones estacionales.

Además, la IA contribuye a prevenir el efecto látigo sincronizando mejor la oferta y la demanda mediante datos en tiempo real, lo que reduce desabastecimientos y mejora la estabilidad de la cadena. En la atención al cliente, los chatbots ofrecen información inmediata sobre pedidos y resuelven consultas frecuentes, agilizando el servicio. En el ámbito financiero, las estrategias de precios dinámicos permiten ajustar costos en tiempo real para mantener la competitividad.

La capacidad predictiva de la IA también resulta clave para anticipar la demanda, planificar suministros y definir niveles de stock de seguridad, evitando faltantes o excesos. De igual manera, identifica las rutas de transporte más eficientes y se ajusta a interrupciones, lo que reduce costos y consumo de combustible. A nivel operativo, analiza datos de producción para detectar factores que afectan el rendimiento, optimizando procesos y reduciendo pérdidas.

Por otro lado, la IA fortalece la gestión de riesgos al prever interrupciones y peligros en la cadena de suministro, garantizando continuidad y seguridad. También mejora la gestión de pedidos al automatizar su enrutamiento y adaptarse a las preferencias de los clientes, incrementando su satisfacción. Finalmente, en la logística inversa, analiza devoluciones y reparaciones para decidir si un producto debe reacondicionarse o descartarse, optimizando costos y aumentando la eficiencia en la gestión de retornos.

En conjunto, estas aplicaciones permiten operaciones logísticas más rápidas, seguras y eficientes, generando ahorros, estabilidad y una mejor experiencia tanto para las empresas como para los clientes.

Fase 2: Análisis Detallado y Componentes del Caso de Uso

Actividad 2.1: Describir claramente el problema que el Machine Learning busca resolver en el caso de uso seleccionado. Además, identificar qué tipo de aprendizaje se está utilizando (supervisado, no supervisado o de refuerzo) y argumentar por qué es el adecuado para esa solución.

Problema: predecir ventas diarias/semanales por SKU-tienda para fijar stock objetivo, puntos de pedido y reposición.

Aprendizaje:

- Supervisado (principal): series temporales y tabular para y = ventas futuras por SKU-tienda; es adecuado por contar con históricos etiquetados. M5 (Walmart) es el referente público.
- Refuerzo (complementario): para política de reabastecimiento en red multi-eslabón, optimizando costo/servicio bajo incertidumbre. Evidencia en “beer game” y estudios recientes de RL multi-eslabón.

El reto central en la logística y la cadena de suministro clásica es la falta de precisión en el pronóstico de demanda, inventarios desbalanceados, rutas ineficientes y entregas poco visibles o tardías. Por ejemplo:

- **Pronóstico de demanda e inventarios:** El uso de métodos tradicionales (como hojas de cálculo) se ve superado por la volatilidad del mercado. La IA y el ML permiten anticipar la demanda con mayor exactitud, evitando tanto faltantes como excedentes.
- **Optimización de rutas y utilización vehicular:** Uber Freight aplica ML para asignar cargas de manera más eficiente, reduciendo los trayectos en vacío en un 10-15 %, lo que impacta positivamente costos y huella de carbono.
- **Última milla y visibilidad en tiempo real:** Este segmento representa aproximadamente el 41 % de los costos logísticos. Empresas como Veho, Dispatch y Amazon utilizan IA y ML para optimizar rutas en tiempo real, prevenir errores y aumentar la satisfacción del cliente.

a) Supervisado

Uso: Pronóstico de demanda, gestión de inventarios, estimación de tiempos de entrega.

Justificación: Dispone de datos históricos etiquetados (por ejemplo, ventas pasadas, condiciones del clima, eventos promocionales) que permiten entrenar modelos predictivos con precisión.

b) Reforzamiento (Reinforcement Learning)

Uso: Optimización dinámica de rutas, gestión de inventarios multinivel, coordinación entre múltiples nodos (almacenes, tiendas).

Justificación: Permite aprender a partir de interacciones en escenarios estocásticos, optimizando una función de recompensa por ejemplo, minimizar costos logísticos o tiempos de entrega.

c) No supervisado / Semi-supervisado

Uso: Detección de fraudes, identificación de anomalías en datos de suministro, segmentación de proveedores.

Justificación: Perfecto cuando no se cuenta con etiquetas claras sobre los datos anómalos o fraudulentos.

Actividad 2.2: Investigar y detallar qué algoritmos específicos de Machine Learning están siendo implementados en el caso de uso (por ejemplo, Regresión Logística, Random Forest, K-Means, Redes Convolucionales). También, identificar las principales herramientas, librerías o plataformas de ML que se mencionan en su implementación.

SUB-TAREA	OBJETIVO	ALGORITMOS RECOMENDADOS	HERRAMIENTAS
Forecasting por SKU-tienda	Predecir demanda	<ul style="list-style-type: none"> • Gradient Boosting, • Prophet/SARIMAX 	<ul style="list-style-type: none"> • scikit-learn, • xgboost, • lightgbm, • statsmodels, • prophet, • TensorFlow/PyTorch
Inventario (policy tuning)	Punto de pedido,	RL profundo (DQN/PPO)	<ul style="list-style-type: none"> • stable-baselines, • ray[rllib]

	stock de seguridad		
Plan de reabastecimiento	Nivel de servicio mínimo con costo	Optimización estocástica	<ul style="list-style-type: none"> Python

Fase 3: Métrica, Evaluación y Contexto

Actividad 3.1: Determinar qué métricas se utilizan para evaluar el rendimiento del modelo de Machine Learning en el caso de estudio (por ejemplo, precisión, recall, F1-score para clasificación; RMSE, MAE para regresión; Silhouette Score para clustering). Explicar brevemente cómo estas métricas ayudan a validar la efectividad de la solución.

Pronóstico (regresión/series):

- MAE (error medio absoluto) y RMSE: magnitud del error
- RMSE penaliza outliers.
- MAPE/WMAPE: error porcentual.
- Pinball loss / cobertura de P50/P90 si necesitas intervalos (útil para inventarios).

Inventario (simulación/política):

- Fill rate, OTIF, costo total (holding + backorder + pedido), rotación.
- En RL, recompensa = $-\text{costo total con penalizaciones por quiebre/obsolescencia}$.

Diseño de evaluación:

1. Hold-out temporal por tienda/SKU (p. ej., últimas 4–8 semanas),
2. backtesting con ventana rodante,
3. champion/challenger
4. AB operativo (piloto en subconjunto de tiendas).

COMPONENTE	MÉTRICA	CÓMO VALIDA EFECTIVIDAD
Forecast	WMAPE / MAPE, MAE/RMSE, Pinball loss P50/P90	Exactitud absoluta y porcentual; intervalos calibrados para stock de seguridad
Inventario	Fill-rate, OTIF, Costo total (posesión, pedido, quiebre)	Mide servicio real al cliente y costo económico
Operación	Rotación, Días de inventario, Tasa de quiebres	Traduce el pronóstico en salud de inventario

Fase 4: Consolidación y Presentación

Actividad 4.1: Recopilar toda la información investigada y organizarla en un informe coherente. El informe debe incluir una introducción, el desarrollo de las fases anteriores y conclusiones claras sobre el caso de uso.

Actividad 4.2: Preparar una breve presentación (o un resumen ejecutivo) que destaque los puntos clave de su caso de uso: el problema, la solución de ML, los algoritmos/herramientas, las métricas y el impacto.

Conclusiones.

1. Un modelo global LightGBM que combine señales de calendario, precio y comportamiento histórico capta mejor la estacionalidad y los picos de demanda que reglas estáticas o *baselines* simples. Esto se traduce en menor error WMAPE, MAE, RMSE y planes de compra más realistas.
2. Al convertir las predicciones en stock de seguridad, puntos de pedido y reabastecimiento, se mejora el fill-rate y se reduce el capital inmovilizado. El beneficio proviene tanto de evitar quiebres como de recortar sobreinventario.
3. Los lags y promedios móviles explican gran parte de la señal, el precio relativo y los eventos de calendario ayudan a anticipar cambios por promociones o feriados. Esto da palancas claras a comercial y abastecimiento.
4. Los precios incompletos, fechas mal alineadas o outliers degradan el pronóstico. Son imprescindibles rutinas de depuración (imputación, controles de coherencia) y trazabilidad para explicar resultados.
5. La demanda sufre drift por factores externos promos, estacionalidad nueva, shocks. Un esquema champion/challenger, umbrales de drift y reentrenos periódicos sostienen la precisión.
6. WMAPE y pérdidas por cuantiles (P50/P90) son más estables que MAPE puro y permiten dimensionar mejor el stock de seguridad con intervalos de predicción, reduciendo tanto quiebres como exceso de cobertura.
7. Antes de escalar conviene probar en un subconjunto de tiendas/SKU midiendo fill-rate, OTIF, tasa de quiebres, costo total y rotación. Esto evidencia el impacto económico real y ajusta la política a la realidad operativa.
8. Con el notebook ejecutable y un flujo reproducible, el esfuerzo técnico es moderado. Integrar luego a nube y tableros de KPIs facilita la operación continua y la colaboración entre áreas.